

基于局部半径的三支DBSCAN算法

申秋萍, 张清华, 高满, 代永杨

引用本文

申秋萍, 张清华, 高满, 代永杨. [基于局部半径的三支DBSCAN算法](#)[J]. 计算机科学, 2023, 50(6): 100-108.

SHEN Qiuping, ZHANG Qinghua, GAO Man, DAI Yongyang. [Three-way DBSCAN Algorithm Based on Local Eps](#) [J]. Computer Science, 2023, 50(6): 100-108.

相似文章推荐 (请使用火狐或 IE 浏览器查看文章)

Similar articles recommended (Please use Firefox or IE to view the article)

[基于三支聚类的云任务优化调度](#)

Optimal Scheduling of Cloud Task Based on Three-way Clustering

计算机科学, 2022, 49(11A): 211100139-7. <https://doi.org/10.11896/jsjcx.211100139>

[基于改进的SLIC和聚类算法结合的高分辨率遥感海冰图像分割](#)

High-resolution Remote Sensing Sea Ice Image Segmentation Based on Combination of ImprovedSLIC Algorithm and Clustering Algorithm

计算机科学, 2022, 49(11A): 211200100-6. <https://doi.org/10.11896/jsjcx.211200100>

[基于三角不等式判定和局部策略的高效邻域覆盖模型](#)

Efficient Neighborhood Covering Model Based on Triangle Inequality Checkand Local Strategy

计算机科学, 2022, 49(5): 152-158. <https://doi.org/10.11896/jsjcx.210300302>

[基于变分自编码器的不平衡样本异常流量检测](#)

Detection of Abnormal Flow of Imbalanced Samples Based on Variational Autoencoder

计算机科学, 2021, 48(7): 62-69. <https://doi.org/10.11896/jsjcx.200600022>

[一种改进的DBSCAN算法在Spark平台上的应用](#)

Application of Improved DBSCAN Algorithm on Spark Platform

计算机科学, 2020, 47(11A): 425-429. <https://doi.org/10.11896/jsjcx.190700071>

基于局部半径的三支 DBSCAN 算法

申秋萍¹ 张清华^{1,2} 高 满¹ 代永杨¹

1 重庆邮电大学计算智能重庆市重点实验室 重庆 400065

2 重庆邮电大学旅游多源数据感知与决策技术文化和旅游部重点实验室 重庆 400065

(sqp6750@163.com)

摘 要 DBSCAN(Density-Based Spatial Clustering of Applications with Noise)是一种经典的基于密度的聚类算法,它通过两个全局参数即半径 Eps 和最少点数 MinPts,能够对任意形状的数据进行聚类,并自动确定类个数。但是,使用全局半径的 DBSCAN 对于密度不均匀数据集的聚类效果较差,且无法对重叠数据集进行聚类。因此,定义了密度递减原则和局部半径,并根据 k-近邻距离自动确定局部半径,从而提出了基于局部半径的 DBSCAN 算法(LE-DBSCAN);然后,通过考虑近邻的标签,对二支聚类结果的临界点和噪声点进行重新划分,从而提出了基于局部半径的三支 DBSCAN 算法(LE3W-DBSCAN)。将 LE-DBSCAN 和 LE3W-DBSCAN 与该领域的相关算法在 UCI 数据集和人工数据集上进行对比,实验结果表明,所提算法在常用的硬聚类指标和软聚类指标上都具有较好的表现。

关键词: 三支聚类;DBSCAN;局部半径;多密度;重叠数据集

中图法分类号 TP391

Three-way DBSCAN Algorithm Based on Local Eps

SHEN Qiuping¹, ZHANG Qinghua^{1,2}, GAO Man¹ and DAI Yongyang¹

1 Chongqing Key Laboratory of Computational Intelligence, Chongqing University of Posts and Telecommunications, Chongqing 400065, China

2 Key Laboratory of Tourism Multisource Data Perception and Decision, Ministry of Culture and Tourism, Chongqing University of Posts and Telecommunications, Chongqing 400065, China

Abstract Density-based spatial clustering of applications with noise(DBSCAN) is a classical density-based clustering algorithm. It clusters dataset of arbitrary shape through two global parameters: radius Eps and minimum number of points MinPts, and automatically determines the number of clusters. However, DBSCAN with global Eps has poor clustering effect on datasets with uneven density, and cannot cluster overlapping datasets. Therefore, the clustering principle of decreasing density and local Eps are defined in this paper. The local Eps is automatically determined according to the k-nearest neighbor distance, and the DBSCAN algorithm based on local Eps(LE-DBSCAN) is proposed. Then, by considering the labels of the nearest neighbors, the border points and noises in the two-way clustering results are redivided, and the three-way DBSCAN algorithm based on local Eps(LE3W-DBSCAN) is proposed. LE-DBSCAN and LE3W-DBSCAN are compared with the related algorithms in this field on UCI datasets and artificial datasets. Experimental results show that the proposed algorithm has good performance both in common hard clustering indices and soft clustering indices.

Keywords Three-way clustering, DBSCAN, Local Eps, Multi-density, Overlapping datasets

1 引言

聚类是一种无监督的机器学习算法,也是数据挖掘中的一个重要分支^[1-2]。随着大数据的发展,聚类技术已经被应用于众多领域,如知识图谱^[3]、统计学^[4]、生物学^[5]、图像处理^[6]、模式识别^[7]和医疗健康^[8-9]等。传统的聚类算法主要有

划分方法、密度方法、层次方法、网格方法和模型方法这 5 种,其中基于划分和密度的聚类算法应用最为广泛。但基于划分的聚类算法大部分是基于距离的,因此只适用于球形或异球形的数据集,并且都需要人工给定类簇个数。基于密度的聚类算法与其他聚类算法的根本区别,就是其可以处理任何形状的数据集。密度峰值^[10-11]和 DBSCAN^[12]等算法都是具有

到稿日期:2022-08-08 返修日期:2022-11-21

基金项目:国家重点研究发展计划(2020YFC2003502);国家自然科学基金(61876201);重庆英才名家名师项目(CQYC20210202215)

This work was supported by the National Key Research and Development Program of China(2020YFC2003502), National Natural Science Foundation of China(61876201) and Talented Masters and Teachers Project of Chongqing(CQYC20210202215).

通信作者:张清华(zhangqh@cqupt.edu.cn)

代表性的基于密度的聚类算法。

传统的聚类算法也被称为硬聚类或二支聚类,它们假设所有类簇都具有清晰的边界,任意类簇之间都不存在重叠的区域^[13]。但是,现实中的数据往往呈现出模糊、重叠的特性,使用传统的硬聚类算法处理这类数据会出现模糊信息和重叠信息的丢失。比如在医疗健康领域中,经常存在无法准确判断病人是否患有某种疾病,或者一位病人同时患有多种疾病的情况,而传统的硬聚类算法只能将病人划分到某一个疾病的类中,无法对这些模糊的数据进行特定的标记。因此,各种软聚类算法或三支聚类算法被提出,用来解决数据模糊性和重叠性的问题^[14-15]。Yu 等将三支决策理论融入传统聚类,提出了三支聚类框架,使用正域、负域和边界域表示一个类^[16-17]。Wang 等结合数学形态学的腐蚀和膨胀的思想,提出了基于收缩与扩张的三支聚类算法^[18]。Zhang 将三支决策理论与 K-Means 算法结合,提出了 TCM 算法^[19];并受 Maji 等提出的 RFCM^[20]算法中对评价指标定义的启发,提出了软聚类专用的评价指标。

DBSCAN^[12]是由 Ester 等提出的一种经典的基于密度的聚类算法,它使用两个全局参数,即半径 Eps 和最少点数 $MinPts$,规定了密度范围,并将符合该密度范围的点的最大集合定义为一个簇。DBSCAN 由于能够自动确定类簇的个数,且可以对任意形状的数据集进行聚类,因此被广泛使用。然而,DBSCAN 仍然存在一些不足:1)使用全局的半径,无法对密度不均匀的数据进行聚类,且参数的设定过于敏感,参数过大或过小都会导致算法无法得到正确的类簇个数,聚类结果较差;2)现有的 DBSCAN 算法以及它的扩展算法都属于二支聚类算法,无法处理模糊、重叠的数据集。针对这些问题,人们提出很多对 DBSCAN 算法的改进方法。例如,Hu 等提出的 KR-DBSCAN 算法使用反向最近邻和影响空间定义了新的扩展条件,从而区分不同密度的相邻类簇^[21]。Chen 基于核密度估计理论提出的自适应计算半径的方法,克服了多密度环境下无法正确聚类的问题^[22]。Yu 等利用缩放函数将原始距离矩阵进行规范化,并将改进的 DBSCAN 算法与三支决策理论相结合,提出了 3W-DBSCAN 算法^[23]。然而,现有研究仍然存在参数过于敏感和聚类结果过于模糊等缺陷,难以得到较好的聚类结果。

为了解决以上问题,本文提出了可处理多密度重叠数据的基于局部半径的三支 DBSCAN 算法,并将其称为 LE3W-DBSCAN。本文的主要创新点如下:

(1)对于密度不均匀的数据集,定义了密度递减原则和局部半径,每次在未分类数据中选择密度最大的点作为新类簇的第一个点,并跟据该点的 k -近邻距离自动确定该类簇的局部半径,从而提出了基于局部半径的 DBSCAN 算法(LE-DBSCAN)。

(2)对于重叠数据集,受 Yu 的三支 DBSCAN 算法的启发,首先基于 LE-DBSCAN 算法得到二支聚类结果,然后通过考虑近邻对象的类标签,对边界点和噪声点进行重新划分,得到三支聚类结果,从而提出了基于局部半径的三支 DBSCAN 算法(LE3W-DBSCAN)。

本文第 2 节介绍了 DBSCAN 算法的基本定义和算法

流程;第 3 节提出了 LE-DBSCAN 和 LE3W-DBSCAN 算法,介绍了算法的主要思想和算法流程;第 4 节将所提出的算法与该领域的相关算法在 UCI 数据集和人工数据集上进行对比,验证了所提算法的优势;最后总结全文。

2 相关工作

为了便于理解本文所提出的算法,本节分别介绍了 DBSCAN 算法的基本定义和算法流程,以及三支聚类的基本定义和性质。

2.1 DBSCAN 算法

DBSCAN 算法^[12]是一种经典的基于密度的聚类算法,它将密度足够高的区域划分成一个类,因此具有能够发现任意形状类簇和识别噪声的优势。DBSCAN 算法需要人工设定两个全局的参数,即半径 Eps 和最少点数 $MinPts$ 。DBSCAN 算法的相关定义如下。

定义 1(Eps 邻域) 对于对象集合 X , $p \in X$, 点 p 的 Eps 邻域 $N_{Eps}(p)$ 定义为:

$$N_{Eps}(p) = \{q \in X | dist(p, q) \leq Eps\}$$

其中, $dist(p, q)$ 表示两点的距离函数, 本文将欧几里得距离作为距离函数。

DBSCAN 算法将所有对象分为 3 种:若 $|N_{Eps}(p)| \geq MinPts$, 则称点 p 为核心点;若 $1 < |N_{Eps}(p)| < MinPts$, 则称点 p 为边界点;若 $|N_{Eps}(p)| = 1$, 则称点 p 为噪声点。

定义 2(直接密度可达) 若点 p 是核心点, 且点 $q \in N_{Eps}(p)$, 则称从 p 到 q 直接密度可达。

定义 3(密度可达) 对于给定的一个对象序列 $p_1, p_2, \dots, p_n$, 若 $p_1 = p, p_n = q$, 且对于任意的 $i \in [1, n]$ 都满足从 p_i 到 p_{i+1} 直接密度可达, 则称从 p 到 q 密度可达。

定义 4(密度相连) 若存在点 o , 满足点 p 和点 q 都是到 o 密度可达, 则称 p 到 q 是密度相连的。

定义 5(类簇) 对于对象集合 X 的任意非空子集 C , 假如 C 满足以下两点, 则称 C 是一个类簇:1) $\forall p, q$, 如果 $p \in C$ 且从 p 到 q 密度可达, 则 $q \in C$;2) $\forall p, q \in C$, p 和 q 都是直接密度可达或密度相连的。

DBSCAN 算法的大致流程为:1)输入参数 Eps 和 $MinPts$;2)在对象集合中随机选择未被分类的点 p , 如果 p 是核心点, 则创建一个新的类簇, 并从 p 开始迭代算法, 直到发现所有密度可达或密度相连的邻点, 并将这些邻点也划分到该类簇, 否则将点 p 视为噪声点;3)重复步骤 2), 直到除噪声点以外的所有对象都被分类。

2.2 三支聚类

三支聚类框架由 Yu 等提出, 用来解决重叠数据集的聚类问题^[16-18]。设讨论的对象集合为 $X = \{x_1, x_2, \dots, x_i, \dots, x_n\}$, 其中 n 是对象个数, x_i 代表一个对象, $1 \leq i \leq n$ 。聚类结果为 $C = \{C_1, C_2, \dots, C_j, \dots, C_c\}$, 其中 c 是类的个数, c_j 代表一个类, $1 \leq j \leq c$ 。与传统的二支聚类不同, 三支聚类中每个类由 3 个部分表示, 即正域、负域和边界域, 分别记为 C^p, C^N, C^b 。其中, 一个类簇的正域是完全属于该类的对象的集合;负域是完全不属于该类的对象的集合;边界域是既属于该类也属于其他类, 或不完全属于该类簇的对象的集合。显然,

$$C^N = X - (C^P \cup C^B).$$

三支聚类中所有类簇都满足以下性质:

- (1) $C_j = C_j^P \cup C_j^B$, $C_j \neq \emptyset$, $j=1, \dots, c$
- (2) $X = C_j^P \cup C_j^B \cup C_j^N$, $j=1, \dots, c$
- (3) $X = \bigcup_{j=1}^c C_j$, $j=1, \dots, c$
- (4) $C_j^P \cap C_j^B = \emptyset$, $j=1, \dots, c$
- (5) $C_j^P \cap C_j^N = \emptyset$, $j=1, \dots, c$
- (6) $C_j^B \cap C_j^N = \emptyset$, $j=1, \dots, c$
- (7) $C_i^P \cap C_j^P = \emptyset$, $i \neq j$, $i=1, \dots, c$, $j=1, \dots, c$
- (8) $C_i^P \cap C_j^B = \emptyset$, $i \neq j$, $i=1, \dots, c$, $j=1, \dots, c$

从以上性质可知,当所有类簇的边界域都为空,即 $\forall j \in [1, c]$, $C_j^B = \emptyset$ 时, $C_j = C_j^P$, $X = C_j^P \cup C_j^N$, 此时聚类结果就是二支聚类。因此,三支聚类是二支聚类的一种特殊情况。

3 LE3W-DBSCAN 聚类算法

根据 DBSCAN 算法的思想,半径 Eps 和最少点数 $MinPts$ 是用来限制密度的两个重要参数,它们是全局使用的。算法通过调整这两个参数,使其满足所有类簇的密度需求,才能得到较好的聚类结果。然而,对于密度不均匀的数据集,没有参数能同时满足所有类簇的不同密度需求。以图 1 中的 Compound 数据集为例,可见类 C_1 的密度明显小于其他类,导致参数无法选择。假如所选的参数满足 C_1 的密度,那么对于其他类簇来说,参数限制的密度过小,会导致其他类簇无法被区分开;假如所选的参数满足除 C_1 以外的类簇的密度,那么对于 C_1 来说,参数限制的密度过大,会导致 C_1 被分成多个类簇,或被当成噪声;并且类簇 C_3 和 C_4 之间没有清晰的边界,难以对它们中间的几个对象进行划分。




图 1 多密度数据集示例

Fig. 1 Examples of multi-density dataset

为了解决密度不均匀和重叠数据集的聚类问题,本文提出了基于局部半径的三支 DBSCAN 算法(LE3W-DBSCAN)。

3.1 基于局部半径的 DBSCAN 算法

在使用 DBSCAN 的聚类思想对密度不均匀的数据集进行聚类时,由于类簇的密度不同,在最少点数 $MinPts$ 不变的情况下,类簇的密度越大,半径的取值应该越小,反之,半径的取值应该越大。因此,本文提出了基于局部半径的 DBSCAN 算法,并称之为 LE-DBSCAN。局部半径的定义如下。

定义 6(局部半径) 在使用 LE-DBSCAN 算法对集合 X 进行聚类时,根据每个类簇 C_j 的密度计算相应的半径 Eps_j ,称半径 Eps_j 为类簇 C_j 的局部半径或局部 Eps 。

此时,假设点 $p \in C_j$,类簇 C_j 的局部半径为 Eps_j 。若 $|N_{Eps_j}(p)| \geq MinPts$,则称点 p 为核心点;若 $1 < |N_{Eps_j}(p)| <$

$MinPts$,则称点 p 为边界点;若 $|N_{Eps_j}(p)| = 1$,则称点 p 为噪声点。

在真实的聚类环境下,数据的分布和类簇的个数都是未知的,因此无法人为输入每个类簇的局部半径。本文提出了根据 k -近邻距离自适应计算局部半径的方法。 k -近邻距离的定义如下。

定义 7(k -近邻距离) 对于对象集合 X ,任意点 $p \in X$,假设将集合 X 中所有对象到点 p 的距离由小到大进行排序,为 $d_1, d_2, \dots, d_k, \dots, d_n$,则称第 k 个距离 d_k 为点 p 的 k -近邻距离, $1 \leq k \leq n$ 。

在选定类簇的第一个点后,如果该点所在的类簇密度较小,那么它的 k -近邻距离较大;反之,该点的 k -近邻距离较小。因此将类簇第一个点的 k -近邻距离作为该类簇的局部半径,不但能够自适应地计算局部半径,而且可以将人工参数从半径 Eps 转化为近邻序数 k ,避免了人工参数过于敏感的问题,降低了人为确定参数的难度。一般而言, k 的取值大于最少点数 $MinPts$,小于对象个数 n 。

另外,如图 1 中的例子所示,假设第一次随机选择的是密度最大的类簇中的对象,则不会不影响其他类簇的聚类。但是,如果第一次随机选择的是图 1 中类簇 C_1 中的对象,由于它的密度较小,会计算得到较大的半径,可能会导致其他几个类簇无法被区分开。为了解决这类问题,本文提出了密度递减的聚类原则,即按照所有类簇的密度从大到小进行聚类。密度递减原则的具体实现方法和基于局部半径的 DBSCAN 算法(LE-DBSCAN)的详细流程如下。

步骤 1 输入最少点数 $MinPts$ 和近邻次序 k 。

步骤 2 根据密度函数计算所有对象的密度,在本文所提算法中,将每个对象到它最近的 $MinPts$ 个近邻的距离的平均值作为密度函数。

步骤 3 根据密度递减原则进行聚类。即对于新的类簇 C_j ,在对象集合 X 中选择未被分类的点中密度最大的点 p 作为新的类簇 C_j 的第一个点。

步骤 4 根据点 p 的 k -近邻距离计算类簇 C_j 的局部半径。

步骤 5 根据最少点数 $MinPts$ 和局部半径 Eps_j ,得到核心点、边界点和噪声点集合。从点 p 开始迭代算法,直到发现点 p 所有密度可达或密度相连的邻点,并将这些邻点也划分到类簇 C_j 。

步骤 6 $j = j + 1$,重复步骤 2—步骤 5,直到除噪声点以外的所有对象都被分类。

根据算法流程可知,LE-DBSCAN 算法通过依次选择未分类数据中最大密度的点,实现对类簇从高密度到低密度的聚类顺序,并且通过 k -近邻距离自动计算类簇的局部半径,实现了对多密度数据的聚类,同时也降低了参数的敏感度。

3.2 考虑近邻标签的三支聚类

本文提出的 LE-DBSCAN 算法能够解决数据密度不均匀的问题,并得到二支聚类结果。而数据中存在的模糊或重叠的问题,仍未得到解决。根据 LE-DBSCAN 算法的定义,核心点的密度较大,且往往处于类簇中靠近中心的位置,具有较强的确定性。但是,边界点和噪声点的密度较低,且处于类簇边缘的位置或者呈散落分布,具有较强的模糊性和重叠性。

因此,本文受文献[23]中 3W-DBSCAN 算法的启发,并对其改进,通过考虑近邻的标签对边界点和噪声点重新进行划分,提出了基于局部半径的三支 DBSCAN 算法,并称之为 LE3W-DBSCAN。算法的具体步骤如下。

步骤 1 根据本文提出的 LE-DBSCAN 算法对数据进行聚类,得到二支聚类结果。

步骤 2 对于对象集合 X 中的任意点 p ,如果点 p 是核心点,且在二支聚类结果中 $p \in C_j$,将点 p 划分到 C_j 的正域,即 $p \in C_j^p$ 。

步骤 3 如果点 p 是边界点,且在二支聚类结果中 $p \in C_j$,求点 p 的 Eps_j 邻域得到 $Eps_j(p)$ 。假如,任意点 $q \in N_{Eps_j}(p)$ 都满足 $q \in C_j$,那么将点 p 划分到 C_j 的正域,即 $p \in C_j^p$ 。假如,对于任意点 $q \in N_{Eps_j}(p)$,存在点 $q \in C_m, m \neq j$,那么将点 p 划分到 C_j 和 C_m 的边界域,即 $p \in C_j^B, p \in C_m^B$ 。

步骤 4 如果点 p 是噪声点,找到距离点 p 最近的核心点 q ,如果在二支聚类结果中 $q \in C_j$,那么将点 p 划分到 C_j 的边界域,即 $p \in C_j^B$ 。

根据步骤 1—步骤 4,最终得到三支聚类结果。与文献[23]中 3W-DBSCAN 不同,该算法中如果边界点 p 的 Eps_j 邻域中的对象都与点 p 属于同一个类 C_j ,那么点 p 仍属于 C_j 的正域,而非边界域;并且本文的算法是基于局部半径,考虑的是 Eps_j 邻域中的近邻的标签,而非全局的 Eps 邻域。因此,本文提出的算法能够得到更加准确的重叠信息,而不会为了保留重叠信息导致聚类结果过于模糊。

3.3 基于局部半径的三支 DBSCAN 算法

本文首先提出 LE-DBSCAN 算法,用于处理数据集密度不均匀的聚类问题。然后,在 LE-DBSCAN 算法得到的二支聚类结果的基础上,通过考虑近邻的标签将二支聚类结果转化为三支聚类结果,并将其称为 LE3W-DBSCAN 算法。算法的流程图如图 2 所示。




图 2 LE3W-DBSCAN 算法流程图

Fig. 2 Flow chart of LE3W-DBSCAN

算法 1 基于局部半径的三支 DBSCAN 算法

```
输入:数据集 X,最少点数 MinPts,近邻次序 k;
输出:聚类结果  $C_j = (C_j^p, C_j^B), 1 \leq j \leq c$ .

1. DistanceMatrix=getDistanceMatrix(X); /* 计算任意两点之间的距离,得到距离矩阵 */
2. DentistMatrix=getDentistMatrix(MinPts, DistanceMatrix); /* 计算所有对象的密度 */
3. clustId=0;
4. while Unclassified objects still exist do;
5. clusterId=clusterId+1;
6. pointId=getMostDensePoint(DentistMatrix); /* 从未分类对象中选择密度最大的点 */
7. EpsclusterId=getEps(pointId, DistanceMatrix, k); /* 计算类簇的局部半径 */
8. twoWayResult = expandC ( pointId, clusterId, EpsclusterId, MinPts); /* 开始扩张类簇 */
9. endwhile
10. for(i=0;i<n;i++)
11. clusterId=getClassLabel(twoWayResult, xi); /* 获取 xi 的类标签 */
12. threeWayReslut=Reclassify(xi, EpsclusterId); /* 将边界点和噪声点重新分类,确定类簇的正域和边界域,得到三支聚类结果 */
13. end for
14. return threeWayResult;
```

4 实验分析

为了更加全面地评估算法的有效性,本文使用了硬聚类评价指标和软聚类评价指标对二支聚类算法 LE-DBSCAN 和三支聚类算法 LE3W-DBSCAN 分别进行评估。首先,将 LE-DBSCAN 算法与 DBSCAN 算法^[12]、KR-DBSCAN 算法^[21]和 3W-DBSCAN 算法^[23]的二支聚类结果进行对比,所使用的硬聚类评价指标为常用的 ACC,ARI 和 NMI,相应的实验结果在 4.2 节中给出。然后,将 LE3W-DBSCAN 算法与 3W-DBSCAN 算法的三支聚类结果进行对比,使用的软聚类评价指标由 Maji 等和 Zhang 提出,4.1 节中给出了软聚类评价指标的详细定义,相应的实验结果在 4.3 节中给出。

4.1 实验设置

本文在常用的 UCI 真实数据集和人工数据集上将本文所提算法与其他聚类算法进行对比,数据集的信息如表 1 所列,其中序号 1-5 为人工数据集,序号 6-11 为真实数据集。

表 1 数据集
Table 1 Datasets

序号	数据集	类个数	维度	样本数	来源文献
1	Aggregation	7	2	788	[24]
2	Compound	6	2	399	[25]
3	Pathbased	3	2	300	[26]
4	Jain	2	2	373	[27]
5	Flame	2	2	240	[28]
6	dermatology	6	34	366	[29]
7	ecoli	5	7	210	[29]
8	iris	3	4	150	[30]
9	seeds	3	7	197	[30]
10	wine	3	13	178	[30]
11	haberman	2	3	306	[30]

实验中每个算法的参数都是在合理取值范围内取聚类

LE3W-DBSCAN 算法的伪代码如算法 1 所示。

结果最优的参数值作为最终值。DBSCAN 算法包含两个参数,即最少点数 $MinPts$ 和半径 Eps , 本文将 $MinPts$ 在 $[2, 30]$ 的范围内以 1 的步长进行取值, 将 Eps 在 $[0.01, 0.5]$ 的范围内以 0.001 的步长进行取值。KR-DBSCAN 算法包含一个参数,即近邻数 k , 本文将 k 在 $[2, 30]$ 的范围内以 1 的步长进行取值。3W-DBSCAN 算法包含两个参数,即最少点数 $MinPts$ 和半径 Eps , $MinPts$ 的取值与 DBSCAN 算法中的取值方法相同。由于 3W-DBSCAN 算法的核心思想是使用缩放函数对距离矩阵进行规范化, 然后基于规范化之后的距离矩阵进行聚类, 因此 Eps 的取值与 DBSCAN 算法中的取值方法不同, 本文将 3W-DBSCAN 中的 Eps 在 $[0.1, 2]$ 范围内以 0.0001 的步长进行取值。本文所提出的 LE3W-DBSCAN 算法包含两个参数,即最少点数 $MinPts$ 和近邻序数 k , $MinPts$ 的取值与 DBSCAN 算法中的取值方法相同, k 在 $[2, 100]$ 的范围内以 1 的步长进行取值。

由于硬聚类指标无法评估类簇的正域和边界域之间的关系, 因此本文也使用了软聚类指标对三支聚类结果进行评估。

第一个评价指标是由 Maji 等提出的^[20], 其定义为:

$$\gamma = \frac{1}{n} \sum_{j=1}^c |C_j^p|$$

其中, n 表示样本本数, c 表示类簇个数, C_j^p 表示类 C_j 的正域, $|\cdot|$ 表示集合中对象的个数。因此, γ 表示所有正域的平均质量, 它的值越大, 表示聚类效果越好。

另外两个评价指标是由 Zhang 提出的^[19], 其定义为:

$$\alpha = \frac{1}{c} \sum_{j=1}^c \frac{|C_j^p|}{|C_j^p| + |C_j^b|}$$
$$\alpha^* = \frac{\sum_{j=1}^c |C_j^p|}{\sum_{j=1}^c (|C_j^p| + |C_j^b|)}$$

其中, C_j^b 表示类 C_j 的边界域。 α 和 α^* 分别表示 c 个类簇的平均质量和整体质量, 它们都是值越大表示聚类效果越好。

4.2 二支聚类实验结果

本文使用 DBSCAN 算法、KR-DBSCAN 算法、3W-DBSCAN 算法与本文所提出的 LE-DBSCAN 算法对 11 个常用数据集进行聚类, 其中, LE-DBSCAN 算法在聚类过程中得到的局部半径详细数值由表 2 所列。各算法对人工数据集的聚类效果如图 3—图 7 所示。对真实数据集和人工数据集进行聚类得到的二支聚类结果, 在硬聚类指标上的得分如表 3 所列。

表 2 LE-DBSCAN 计算得到的局部半径
Table 2 Local Eps obtained by LE-DBSCAN

序号	数据集	类个数	epsC1	epsC2	epsC3	epsC4	epsC5	epsC6	epsC7
1	Aggregation	7	0.0513	0.0573	0.0633	0.0690	0.0735	0.0735	0.0635
2	Compound	6	0.0495	0.0556	0.0391	0.0363	0.0401	0.1588	
3	Pathbased	3	0.0561	0.0733	0.1998				
4	Jain	2	0.0666	0.0949					
5	Flame	2	0.0628	0.0680					
6	dermatology	6	1.0628	1.5580	1.4744	1.7321	1.7046	2.3572	
7	ecoli	5	0.1726	0.2411	0.4304	0.4982	1.0266		
8	iris	3	0.3498	0.2927	0.6089				
9	seeds	3	0.3092	0.3993	0.5265				
10	wine	3	0.5970	0.9734	1.1905				
11	haberman	2	0.1926	0.4931					




图 3 Aggregation 二支聚类实验结果

Fig. 3 Experimental results of two-way clustering of Aggregation




图 4 Compound 二支聚类实验结果

Fig. 4 Experimental results of two-way clustering of Compound




图 5 Pathbased 二支聚类实验结果

Fig. 5 Experimental results of two-way clustering of Pathbased




图 6 Jain 二支聚类实验结果

Fig. 6 Experimental results of two-way clustering of Jain




图 7 Flame 二支聚类实验结果

Fig. 7 Experimental results of two-way clustering of Flame

表 3 二支聚类实验结果

Table 3 Experimental result soft two-way clustering

数据集	ACC				ARI				NMI			
	DBSCAN	KR-DBSCAN	3W-DBSCAN	LE-DBSCAN	DBSCAN	KR-DBSCAN	3W-DBSCAN	LE-DBSCAN	DBSCAN	KR-DBSCAN	3W-DBSCAN	LE-DBSCAN
1	0.992	0.997	0.997	0.997	0.989	0.995	0.995	0.995	0.983	0.992	0.992	0.992
2	0.822	0.925	0.782	0.952	0.939	0.889	0.760	0.947	0.896	0.896	0.777	0.918
3	0.847	0.967	0.707	0.957	0.707	0.901	0.548	0.872	0.738	0.870	0.689	0.847
4	0.756	1	1	1	0.934	1	1	1	0.833	1	1	1
5	0.938	0.996	0.992	0.996	0.892	0.983	0.967	0.983	0.813	0.963	0.927	0.963
6	0.489	0.738	0.658	0.825	0.371	0.728	0.600	0.741	0.574	0.86	0.707	0.797
7	0.489	0.596	0.679	0.554	0.432	0.392	0.528	0.639	0.441	0.514	0.586	0.584
8	0.740	0.840	0.907	0.907	0.612	0.760	0.759	0.857	0.640	0.792	0.806	0.866
9	0.652	0.600	0.624	0.738	0.502	0.460	0.489	0.490	0.582	0.553	0.605	0.534
10	0.562	0.360	0.612	0.764	0.439	0.461	0.462	0.632	0.564	0.599	0.600	0.627
11	0.621	0.745	0.735	0.758	0.159	0.100	0.151	0.159	0.063	0.055	0.059	0.071

由表 3 可以看出本文提出的 LE-DBSCAN 算法在常用数据集上相对于其他算法具有较好的表现。由图 3—图 7 可以看出,存在 LE-DBSCAN 算法的类簇的序号与其他算法类簇的序号不同的情况,这是因为本文所提出的算法是基于密度递减的顺序进行聚类的。如图 4 所示,以特征最明显的 Compound 数据集为例,图 4(a)原数据集中的类簇 C_1 密度最小,图 4(e)中 LE-DBSCAN 算法的聚类结果中该类簇的序号为 C_6 ,说明密度明显小的类簇会最后被聚类。由表 2 中 LE-DBSCAN 对每个数据集聚类的过程中计算得到的局部半径可以看出,对于密度不均匀的数据集,按照类簇被发现的顺序,其对应的局部半径是非严格递增的,位置靠后的类簇对应的局

部半径明显大于位置靠前的类簇的局部半径;而对于密度较为均匀的数据集,各个类簇的局部半径基本相同。这也说明了 LE-DBSCAN 算法的合理性。

4.3 三支聚类实验结果

本文所提出的 LE3W-DBSCAN 算法与 3W-DBSCAN 算法在人工数据集上的聚类结果如图 8—图 11 所示,由于两个算法对 Jain 数据集的三支聚类结果相同,都是完全正确,因此未展示图的对比。算法得到的三支聚类结果在软聚类指标上的得分如表 4 所列。结合表 3、表 4 可以看出,LE3W-DBSCAN 算法在提升二支聚类效果的同时,也能够保持较好的三支聚类效果。




图 8 Aggregation 三支聚类实验结果

Fig. 8 Experimental results of three-way clustering of Aggregation




图 9 Compound 三支聚类实验结果

Fig. 9 Experimental results of three-way clustering of Compound




图 10 Pathbased 三支聚类实验结果

Fig. 10 Experimental results of three-way clustering of Pathbased




图 11 Flame 三支聚类实验结果

Fig. 11 Experimental results of three-way clustering of Flame

以图 8 中 Aggregation 数据集的聚类结果为例,相对于 3W-DBSCAN 算法的聚类结果,本文所提出的 LE3W-DBSCAN 算法只会将处于类簇边缘或者多个类簇之间、模糊度较强的对象划分到边界域中,避免了聚类结果过于模糊。因此,实验结果说明本文所提出的算法能够较好地平衡聚类的模糊性和确定性,在保留模糊信息的同时,也能够避免必要的确定性信息的丢失。

表 4 三支聚类实验结果

数据集	α		α^*		γ	
	3W-DBSCAN	LE3W-DBSCAN	3W-DBSCAN	LE3W-DBSCAN	3W-DBSCAN	LE3W-DBSCAN
1	0.889	0.977	0.845	0.982	0.854	0.991
2	0.824	0.916	0.962	0.958	0.962	0.960
3	0.807	0.955	0.891	0.954	0.903	0.977
4	0.995	1	0.997	1	0.997	1
5	0.919	0.924	0.925	0.938	0.929	0.942
6	0.258	0.858	0.314	0.867	0.314	0.929
7	0.343	0.609	0.524	0.624	0.532	0.783
8	0.474	0.921	0.487	0.923	0.487	0.960
9	0.550	0.626	0.734	0.638	0.762	0.790
10	0.595	0.883	0.709	0.884	0.713	0.944
11	0.959	0.970	0.974	0.987	0.987	0.993

结束语 基于密度的 DBSCAN 聚类算法具有能够处理任何形状的数据集和自动确定类簇个数的优势,但是无法处理多密度和重叠的数据集。三支聚类结合了传统的硬聚类和三支决策模型的特点,能够对模糊和重叠的数据进行聚类。因此,本文首先根据局部半径和密度递减原则提出了基于局部半径的 DBSCAN 算法,使其能够对多密度数据集进行聚类,并且根据 k -近邻距离自动确定局部半径,避免了参数过于敏感的问题。然后,根据基于局部半径的 DBSCAN 得到的二支聚类结果,通过考虑近邻的类标签对边界点和噪声点重新分类,提出了基于局部半径的三支 DBSCAN 算法,使其能够对多密度、重叠数据集进行聚类。实验结果表明,本文所提出的算法对多密度模糊数据集具有较好的聚类效果。希望本文的研究工作能够对医疗健康等领域产生的多密度模糊的数据进行有效的处理和分析,挖掘出数据中潜在的信息。

参 考 文 献

[1] DAYANAM A,ELBA C T,MARCEL B,et al. Cluster analysis of urban ultrafine particles size distributions[J]. Atmospheric Pollution Research,2019,10(1):45-52.

[2] WU X D,ZHU X Q,WU G Q,et al. Data mining with big data

- [J]. IEEE Transactions on Knowledge and Data Engineering, 2014, 26(1): 97-107.
- [3] HUANG J J, CHEN W, LIU A, et al. Cluster query: a new query pattern on temporal knowledge graph[J]. World Wide Web, 2020, 23(2): 755-779.
- [4] BROWN D, JAPA A, SHI Y. A fast density-grid based clustering method[C]//IEEE 9th Annual Computing and Communication Workshop and Conference. Piscataway, NJ: IEEE, 2019: 48-54.
- [5] GONDEAU A, AOUABED Z, HIJRI M, et al. Object weighting: A new clustering approach to deal with outliers and cluster overlap in computational biology[J]. IEEE ACM Transactions on Computational Biology and Bioinformatics, 2021, 18(2): 633-643.
- [6] XU C Y, LIN R J, CAI J Y, et al. Deep image clustering by fusing contrastive learning and neighbor relation mining [J]. Knowledge Based Systems, 2022, 238: 107967.
- [7] SINGH S, GANIE A H. Applications of picture fuzzy similarity measures in pattern recognition, clustering, and MADM[J]. Expert Systems with Applications, 2021, 168: 114264.
- [8] XU Z Z, SHEN D R, NIE T Z, et al. A cluster-based oversampling algorithm combining SMOTE and k -means for imbalanced medical data[J]. Information Sciences, 2021, 572: 574-589.
- [9] WANG X, WANG J, YU G X, et al. Network regularized bi-clustering for cancer subtype categorization[J]. Chinese Journal of Computers, 2019, 42(6): 1274-1288.
- [10] RODRIGUEZ A, LAIO A. Clustering by fast search and find of density peaks[J]. Science, 2014, 344(6191): 1492-1496.
- [11] LIU R, WANG H, YU X M. Shared-nearest-neighbor-based clustering by fast search and find of density peaks[J]. Information Sciences, 2018, 450: 200-226.
- [12] ESTER M, KRIEGLER H P, SANDER J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]//Proceedings of the Second International Conference on Knowledge Discovery and Data Mining. Portland, Oregon: AAAI Press, 1996: 226-231.
- [13] JAIN A K. Data clustering: 50 years beyond k -means[J]. Pattern Recognition Letters, 2010, 31(8): 651-666.
- [14] DURSO P. Informational Paradigm, management of uncertainty and theoretical formalisms in the clustering framework: A review[J]. Information Sciences, 2017, 400: 30-62.
- [15] PETERS G, CRESPO F A, LINGRAS P, et al. Soft clustering—Fuzzy and rough approaches and their extensions and derivatives [J]. International Journal of Approximate Reasoning, 2013, 54(2): 307-322.
- [16] YU H, JIAO P, YAO Y Y, et al. Detecting and refining overlapping regions in complex networks with three-way decisions[J]. Information Sciences, 2016, 373: 21-41.
- [17] YU H, ZHANG C, WANG G Y. A tree-based incremental overlapping clustering method using the three-way decision theory [J]. Knowledge Based Systems, 2016, 91: 189-203.
- [18] WANG P X, YAO Y Y. CE3: A three-way clustering method based on mathematical morphology[J]. Knowledge Based Systems, 2018, 155: 54-65.
- [19] ZHANG K. A three-way c -means algorithm[J]. Applied Soft Computing, 2019, 82: 105536.
- [20] MAJI P, PAL S K. RFCM: A hybrid clustering algorithm using rough and Fuzzy sets [J]. Fundamenta Informaticae, 2007, 80(4): 475-496.
- [21] HU L H, LIU H K, ZHANG J F, et al. KR-DBSCAN: A density-based clustering algorithm based on reverse nearest neighbor and influence space [J]. Expert Systems With Applications, 2021, 186: 115763.
- [22] CHEN F Y. An improved DBSCAN algorithm for adaptively determining parameters in multi-density environment[C]//2nd International Conference on Artificial Intelligence and Information Systems. New York: ACM, 2021: 1-4.
- [23] YU H, CHEN L Y, YAO J T, et al. A three-way clustering method based on an improved DBSCAN algorithm[J]. Physica A: Statistical Mechanics and its Applications, 2019, 535: 122289.
- [24] GIONIS A, MANNILA H, TSAPARAS P. Clustering aggregation[J]. ACM Transactions on Knowledge Discovery from Data, 2007, 1(1): 1-30.
- [25] ZAHN C T. Graph-theoretical methods for detecting and describing gestalt clusters [J]. IEEE Transactions on Computers, 1971, 100(1): 68-86.
- [26] CHANG H, YEUNG D Y. Robust path-based spectral clustering[J]. Pattern Recognition, 2008, 41(1): 191-203.
- [27] JAIN A, LAW M. Data clustering: A user's dilemma[J]. Lecture Notes in Computer Science, 2005, 3776: 1-10.
- [28] FU L M, MEDICO E. FLAME, a novel fuzzy clustering method for the analysis of DNA microarray data[J]. BMC bioinformatics, 2007, 8(1): 3-3.
- [29] HOU J, ZHANG A H, QI N M. Density peak clustering based on relative density relationship[J]. Pattern Recognition, 2020, 108: 107554.
- [30] XIE J Y, GAO H C, XIE W X, et al. Robust clustering by detecting density peaks and assigning points based on fuzzy weighted k -nearest neighbors[J]. Information Sciences, 2016, 354: 19-40.



SHEN Qiuping, born in 1997, postgraduate. Her main research interests include three-way decisions, machine learning and uncertain information processing.



ZHANG Qinghua, born in 1974, Ph.D., professor, Ph.D supervisor. His main research interests include rough sets, fuzzy sets, granular computing and uncertain information processing.